



Анализ вакансий HH.ru

ИТОГОВЫЙ ПРОЕКТ ПО ПРОГРАММЕ DATA SCIENCE

Анализ датасета вакансий HeadHunter с акцентом на рынок юридических вакансий: зарплатные предложения, требования к опыту, форматы занятости, ключевые навыки и NLP-кластеризация.

Цели и задачи проекта

Цель анализа

Исследовать структуру вакансий, выявить закономерности в зарплатных предложениях и подготовить данные для дальнейшего построения модели прогнозирования зарплаты. Проект охватывает полный цикл анализа данных: от загрузки и проверки качества до NLP-анализа текстового содержания вакансий.

Ключевые задачи

01

Первичный обзор датасета

Размер таблицы, названия столбцов, типы данных

02

Проверка качества данных

Пропуски, дубликаты, корректность значений

03

Анализ распределений

По городам, опыту, типу занятости и графику

04

Зарплатный анализ

Исследование зарплатных предложений и факторов

05

NLP-анализ и кластеризация

TF-IDF, KMeans, сравнение зарплат по кластерам

Загрузка и описание датасета

Датасет содержит выгрузку вакансий с портала HH.ru. В таблице представлены название вакансии, город, работодатель, дата публикации, зарплатная вилка, валюта, требуемый опыт, тип занятости, график работы и ключевые навыки.

Признак	Смысл
id	Уникальный идентификатор вакансии
name	Название вакансии
area	Город или регион размещения
employer	Работодатель
published_at	Дата и время публикации вакансии
salary_from / salary_to	Нижняя и верхняя граница зарплатной вилки
salary_currency	Валюта зарплаты
experience	Требуемый опыт работы
employment	Тип занятости
schedule	График работы
key_skills	Ключевые навыки, указанные работодателем

❗ Наиболее важная целевая переменная для дальнейшей модели — зарплата. Так как в данных есть две границы зарплатной вилки, далее создаётся агрегированный показатель **salary_mean_rur** — средняя зарплата в рублях.

Проверка качества данных

Основные результаты проверки

Дубликаты

В датасете нет дубликатов по строкам и по идентификаторам вакансий (id).

Пропуски

Основные пропуски сосредоточены в полях salary_from и salary_to — типичная особенность данных о вакансиях: работодатель может указать только одну границу или не указать зарплату полностью.

Стратегия работы с пропусками

Полностью удалять строки с пропусками зарплат на раннем этапе нецелесообразно. Для описательного анализа используется весь датасет, для зарплатного — только наблюдения с рассчитанной salary_mean_rur.

Валюты

Подавляющее большинство вакансий указано в рублях. Для зарплатного анализа и модели используется переменная salary_mean_rur, где сохранены только рублёвые зарплаты.

Сводка по датасету

Структура данных

Таблица содержит уникальный идентификатор вакансии, название, город, работодателя, дату публикации, зарплатную вилку, валюту, требуемый опыт, тип занятости, график работы и ключевые навыки

Доля с зарплатой

Доля вакансий с рассчитанной зарплатой (salary_mean_rur) составляет менее 100% — часть работодателей не указывает зарплату или указывает вилку не полностью

Валюты

Основная часть датасета в рублях; зарплаты в USD и EUR без пересчёта по курсу не смешиваются с рублёвыми

- ❑ Зарплатная информация является ключевой для анализа, поэтому полностью удалять строки с пропусками на раннем этапе нецелесообразно.

Предобработка данных

Выполнена базовая подготовка данных для дальнейшего анализа и моделирования.



Преобразование даты

Поле `published_at` преобразовано в формат `datetime`. Созданы календарные признаки: год, месяц, день, день недели (с маппингом на русские названия дней).



Признаки для ML

Добавлены: `skills_count` (количество навыков), `is_remote` (удалённая работа), `is_moscow` (Москва vs остальные), `name_length` и `employer_length` (длина названий).



Средняя зарплата

Создан признак `salary_mean_rur` — среднее по доступным границам вилки в рублях. Если указана только одна граница, используется именно она. Нерублёвые зарплаты заменены на `NaN`.




Фильтрация валют

Нельзя напрямую сравнивать зарплаты в RUR, USD и EUR без пересчёта по курсу. Основная часть датасета в рублях, поэтому для зарплатного анализа используется только `salary_mean_rur`.

Распределение вакансий: города, опыт, занятость


География вакансий

Наибольшее количество вакансий сосредоточено в крупнейших деловых центрах. Лидером является **Москва**, далее идут **Санкт-Петербург** и крупные региональные центры. Отдельно выделяется категория «Удалённо», что показывает заметную роль дистанционного формата на рынке юридических вакансий.



Требования к опыту

Основной спрос приходится на специалистов с опытом **от 1 до 3 лет** и **от 3 до 6 лет**. Это говорит о том, что рынок преимущественно ориентирован на уже подготовленных кандидатов, способных выполнять рабочие задачи без длительного обучения с нуля. Вакансии без опыта также занимают заметную долю, но обычно предполагают более низкий уровень зарплаты и стартовые позиции.



Тип занятости

На рынке доминирует **полная занятость**. При этом удалённая работа занимает значимую долю — особенно важно для юридических, договорных, комплаенс- и документооборотных позиций, где часть задач может выполняться дистанционно.





График работы

Доминирует **полный рабочий день**. Удалённый и гибкий форматы занимают заметную долю и могут быть важными признаками для модели прогнозирования зарплаты.



Анализ зарплатных предложений

Для зарплатного анализа используются только строки, где удалось рассчитать salary_mean_rur. Зарплата в вакансиях — это предложение работодателя, а не фактическая зарплата сотрудника. Часть работодателей может не указывать зарплату или указывать вилку не полностью.

Распределение зарплат

Распределение зарплат имеет **правостороннюю асимметрию**: большинство вакансий сосредоточено в среднем диапазоне, но присутствует длинный «хвост» высоких зарплат. Поэтому для интерпретации рынка **медиана надёжнее среднего**: среднее сильнее реагирует на редкие высокие предложения.

Работа с выбросами

Для корректной визуализации применён **IQR-фильтр** (межквартильный размах). Выбросы не являются «плохими» данными, но для графиков и медианных сравнений их лучше анализировать отдельно.

Зарплата и опыт работы

Опыт работы является одним из наиболее очевидных факторов зарплаты. Вакансии для кандидатов без опыта имеют самый низкий медианный уровень оплаты. С ростом требуемого опыта зарплата **последовательно увеличивается**, а категория «Более 6 лет» формирует наиболее высокий зарплатный сегмент.


Зарплата по городам и форматам

Самые высокие медианные зарплаты наблюдаются в **Москве, Санкт-Петербурге** и в **удалённом формате**. Это объясняется концентрацией крупных работодателей, более высокой стоимостью труда и конкуренцией за квалифицированных специалистов. Удалённые вакансии могут быть связаны с более широким географическим рынком и ориентацией на специалистов с более высокой квалификацией.

Анализ работодателей и ключевых навыков

Топ работодателей

Топ работодателей показывает, какие компании наиболее активно публикуют вакансии. Однако количество публикаций не всегда означает высокий уровень зарплат: крупные работодатели могут массово размещать как стартовые, так и вакансии для юристов с опытом. Поэтому для зарплатных выводов работодателей лучше анализировать дополнительно по медиане и числу вакансий.




Ключевые навыки

В топе навыков находятся компетенции, связанные с:

- Договорная и претензионная работа
- Правовая экспертиза
- Документооборот и деловая переписка
- Переговоры
- Excel, MS Office, legal English
- Закупки, 44-ФЗ, 223-ФЗ
- Арбитраж и процессуальные документы

Это подтверждает, что значительная часть вакансий ориентирована на **прикладную юридическую работу** с документами, договорами и коммуникацией с контрагентами. Работодатели ценят не только юридическую базу, но и прикладные офисные, аналитические и коммуникационные навыки.



NLP-анализ текстов вакансий

После анализа отдельных ключевых навыков исследование расширено с помощью методов NLP. В текстовый корпус объединены название вакансии и список ключевых навыков. Это позволяет анализировать не только отдельные компетенции, но и смысловые сочетания: «договорная работа», «претензионная работа», «арбитражный суд», «44-ФЗ», «legal english».

1

TF-IDF векторизация

Текст вакансий преобразован в числовую матрицу TF-IDF ($\text{ngram_range}=(1, 2)$). Метод снижает вес слишком общих слов и повышает значимость терминов, которые сильнее отличают одни вакансии от других. Выделено 1500 наиболее важных признаков.

2

Кластеризация KMeans

Вакансии сгруппированы на основе текстового сходства. С помощью `silhouette_score` выбрано **6 кластеров** — оптимальное число для интерпретации. Каждой вакансии присвоен номер NLP-кластера.

3

Интерпретация кластеров

Кластеры отражают разные направления юридической работы: договорную, судебную, корпоративную, закупочную, комплаенс- и административно-документарную. Характерные термины каждого кластера позволяют дать ему смысловое название.

4

Зарплаты по кластерам

Сравнение медианных зарплат по NLP-кластерам показывает, что **содержание вакансии связано с уровнем оплаты**: разные типы юридических ролей могут иметь разные зарплатные диапазоны даже внутри одного профессионального рынка.

❗ Признак `nlp_cluster` можно использовать не только для анализа, но и как дополнительный категориальный признак в будущей модели прогнозирования зарплаты.

Итоговые выводы

- 1 Датасет пригоден для анализа**
Нет дубликатов по id, структура данных понятна, основные категориальные признаки заполнены. Главная зона пропусков — зарплатные вилки, что является нормальной особенностью вакансий с HH.ru.
- 2 Рынок сосредоточен в крупных городах**
Больше всего вакансий — в Москве, Санкт-Петербурге и крупных региональных центрах. Отдельно заметна категория удалённой работы, показывающая развитие дистанционного формата.
- 3 Опыт работы существенно связан с зарплатой**
Зарплатный уровень последовательно растёт от вакансий без опыта к вакансиям для специалистов с опытом более 6 лет. Это один из самых интерпретируемых факторов зарплаты.
- 4 Полная занятость доминирует**
Большинство вакансий ориентировано на классический формат занятости. При этом удалённый и гибкий форматы занимают заметную долю и могут быть важными признаками для модели.
- 5 Навыки отражают прикладной юридический профиль**
Наиболее востребованы договорная работа, претензионная работа, правовая экспертиза, работа с документами, деловая переписка, переговоры, Excel и MS Office. Работодателям нужны специалисты, способные работать не только с нормами права, но и с документами и коммуникацией.
- 6 NLP-кластеризация раскрыла тематические группы**
TF-IDF и кластеризация разделили вакансии на группы, отражающие разные направления юридической работы. Сравнение зарплат по кластерам показывает, что не только город и опыт, но и содержание вакансии связано с уровнем оплаты.

✔ **Финальное резюме:** В проекте проведён полный цикл первичного анализа данных. Главный практический результат — понимание факторов, связанных с зарплатой в юридических вакансиях: опыт работы, город, формат занятости, удалённость, работодатель, набор ключевых навыков и тематический NLP-кластер. Такой анализ может использоваться как основа для карьерной аналитики, мониторинга рынка труда и построения прогнозной системы по вакансиям.